Pipeline de Dados na AWS

Medallion Architecture · Bronze → Silver → Gold

ShopBR · E-commerce · AWS · us-east-1

Amazon S3 · AWS Lambda · AWS Glue · Amazon Athena · CloudWatch

Joyce Mara · 2026

O desafio

Contexto

O que foi pedido

Construir um pipeline de dados na AWS para o e-commerce fictício ShopBR, seguindo o padrão Medallion Architecture (Bronze → Silver → Gold).

Os dados chegavam em arquivos CSV sem nenhum tratamento. O objetivo era automatizar a ingestão, limpeza, transformação e disponibilização dos dados para análise, sem intervenção manual.

O que o time de negócio queria saber

- Quais produtos mais venderam no último mês?
- Qual região do Brasil gera mais receita?
- Quais pedidos estão com status em atraso?
- Qual é o ticket médio por categoria de produto?

A solução: Medallion Architecture

Visão geral

A Medallion Architecture organiza os dados em três camadas progressivas, cada uma com um propósito específico.

Bronze

Ingestion

Dado bruto, preservado exatamente como chegou. Nenhuma alteração. Garante rastreabilidade total da origem.

Silver

Processing

Dado limpo, tipado e transformado. Nulos removidos, datas convertidas, particionado por estado para performance.

Gold

Analytics

Dado agregado, pronto para análise. Vendas por estado e mês. Responde diretamente as perguntas do negócio.

Architecture

Visão geral

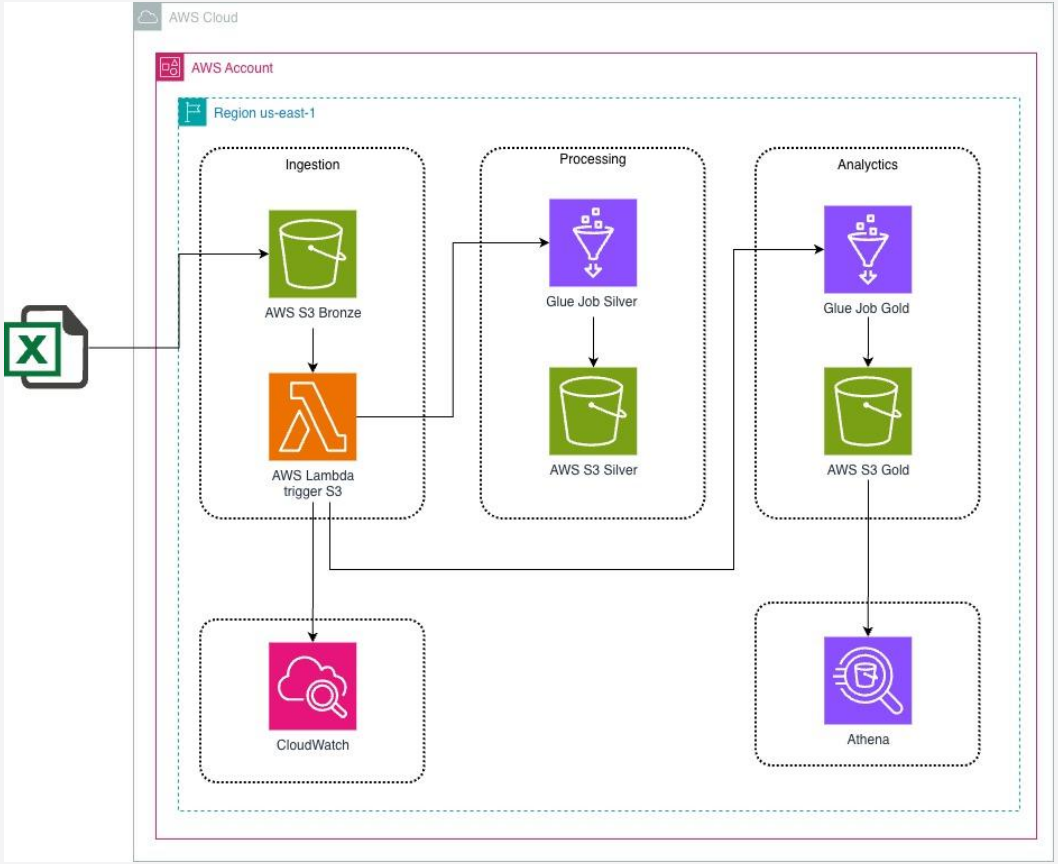

Camada Bronze: Ingestion

Ingestion

O que acontece nessa camada

O arquivo CSV chega no Amazon S3 na pasta bronze/pedidos/. Nenhuma transformação é feita, o dado é preservado exatamente como veio. Isso garante rastreabilidade: se algo der errado no processamento, sempre é possível reprocessar a partir do dado original.

AWS S3

Armazena os CSVs brutos em bronze/pedidos/. Bucket: shopbr-datalake-joyce.

AWS Lambda

Monitora o bucket. Quando detecta um novo arquivo via evento s3:ObjectCreated, aciona automaticamente o pipeline.

AWS CloudWatch

Registra todos os logs de execução. Permite rastrear cada etapa do pipeline e identificar falhas.

Amazon S3: Bucket shopbr-datalake-joyce

Ingestion

shopbr-datalake-joyce Info

Objects | Metadata | Properties | Permissions | Metrics | Management | File systems - *new* | Access Points

Objects (5)

Copy S3 URI | Copy URL | Download | Open | Delete | Actions | Create folder | Upload

Objects are the fundamental entities stored in Amazon S3. You can use Amazon S3 inventory to get a list of all objects in your bucket. For others to access your objects, you'll need to explicitly grant them permissions. Learn more

Find objects by prefix

Show versions

1

Name	Type	Last modified	Size	Storage class
bronze/	Folder	-	-	-
gold_$folder$	-	April 14, 2026, 12:39:53 (UTC+01:00)	0 B	Standard
gold/	Folder	-	-	-
silver_$folder$	-	April 12, 2026, 10:39:01 (UTC+01:00)	0 B	Standard
silver/	Folder	-	-	-

Amazon S3: bronze/pedidos/

Ingestion

pedidos/

Copy S3 URI

Objects | Properties

Objects (2)

Copy S3 URI | Copy URL | Download | Open | Delete | Actions | Create folder | Upload

Objects are the fundamental entities stored in Amazon S3. You can use Amazon S3 inventory to get a list of all objects in your bucket. For others to access your objects, you'll need to explicitly grant them permissions. Learn more

Find objects by prefix

Show versions

1

Name	Type	Last modified	Size	Storage class
pedidos_jan2024.csv	csv	April 6, 2026, 11:57:39 (UTC+01:00)	594.0 B	Standard
testando_lambda5.csv	csv	April 14, 2026, 12:33:56 (UTC+01:00)	1.2 KB	Standard

AWS Lambda: lambda-trigger-glue-shopbr

Ingestion

lambda-trigger-glue-shopbr

Function overview Info

Diagram | Template

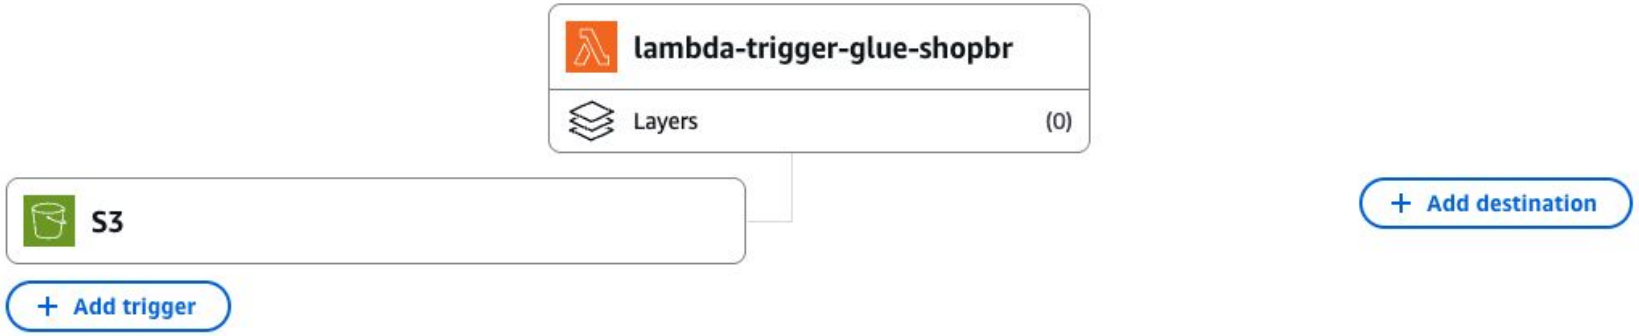

Amazon CloudWatch: Logs do pipeline completo

Ingestion

CloudWatch

Favorites and recents

Ingestion
Dashboards
Alarms 0 0 0

- AI Operations
- GenAI Observability
- Application Signals (APM)
- Infrastructure Monitoring
- Logs
  - Log Management
  - Log Analytics Preview
  - Log Anomalies
  - Live Tail
  - Logs Insights
  - Contributor Insights
- Metrics
- Network Monitoring
- Setup

Log events

Actions | Start tailing | Create metric filter

You can use the filter bar below to search for and match terms, phrases, or values in your log events. Learn more about filter patterns

Filter events - press enter to search

Clear 1m 30m 1h 12h Custom UTC timezone Display

Timestamp	Message
	No older events at this moment. Retry
2026-04-14T11:33:56.765Z	INIT_START Runtime Version: python:3.14.v38 Runtime Version ARN: arn:aws:lambda:us-east-1::runtime:6198fb9c708e4801023245984060390226 4ba8cc36621c703d5cd31b2245e02d1
2026-04-14T11:33:57.110Z	START RequestId: c69f5978-7d0a-4890-8ca5-4a6bb838f889 Version: $LATEST
2026-04-14T11:33:57.268Z	[INFO] 2026-04-14T11:33:57.268Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Found credentials in environment variables.
2026-04-14T11:33:59.266Z	[INFO] 2026-04-14T11:33:59.266Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Novo arquivo detectado: s3://shopbr-datalake-joyce/bronze/pedidos/testando_lambda5.csv
2026-04-14T11:33:59.671Z	[INFO] 2026-04-14T11:33:59.671Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Job Silver iniciado: jr_0cf51b1159284bc4d11a94596098d747ace047d701a5ab53148d27e680bc5a99
2026-04-14T11:33:59.713Z	[INFO] 2026-04-14T11:33:59.713Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [job] Estado: RUNNING | 0s decorridos
2026-04-14T11:34:29.785Z	[INFO] 2026-04-14T11:34:29.785Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [job] Estado: RUNNING | 30s decorridos
2026-04-14T11:34:59.850Z	[INFO] 2026-04-14T11:34:59.850Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [job] Estado: RUNNING | 60s decorridos
2026-04-14T11:35:29.924Z	[INFO] 2026-04-14T11:35:29.924Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [job] Estado: SUCCEEDED | 90s decorridos
2026-04-14T11:35:29.924Z	[INFO] 2026-04-14T11:35:29.924Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Job Silver concluido!
2026-04-14T11:35:39.665Z	[INFO] 2026-04-14T11:35:39.665Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Crawler Silver iniciado!
2026-04-14T11:35:39.706Z	[INFO] 2026-04-14T11:35:39.706Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-silver] Estado: RUNNING | 0s decorridos
2026-04-14T11:36:09.750Z	[INFO] 2026-04-14T11:36:09.750Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-silver] Estado: RUNNING | 30s decorridos
2026-04-14T11:36:39.796Z	[INFO] 2026-04-14T11:36:39.796Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-silver] Estado: RUNNING | 60s decorridos
2026-04-14T11:37:09.838Z	[INFO] 2026-04-14T11:37:09.838Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-silver] Estado: STOPPING | 90s decorridos
2026-04-14T11:37:39.892Z	[INFO] 2026-04-14T11:37:39.892Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-silver] Estado: STOPPING | 120s decorridos
2026-04-14T11:38:09.939Z	[INFO] 2026-04-14T11:38:09.939Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-silver] Estado: STOPPING | 150s decorridos
2026-04-14T11:38:39.986Z	[INFO] 2026-04-14T11:38:39.986Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-silver] Estado: READY | 180s decorridos
2026-04-14T11:38:39.986Z	[INFO] 2026-04-14T11:38:39.986Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Crawler Silver concluido!
2026-04-14T11:38:40.122Z	[INFO] 2026-04-14T11:38:40.122Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Job Gold iniciado: jr_ec06c142a3a9b0ef64f4c1a54ff71cb4dc8d00d873dbf8256ca2cce00280f534
2026-04-14T11:38:40.161Z	[INFO] 2026-04-14T11:38:40.161Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [jobGold] Estado: RUNNING | 0s decorridos
2026-04-14T11:39:10.225Z	[INFO] 2026-04-14T11:39:10.225Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [jobGold] Estado: RUNNING | 30s decorridos
2026-04-14T11:39:40.286Z	[INFO] 2026-04-14T11:39:40.286Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [jobGold] Estado: RUNNING | 60s decorridos
2026-04-14T11:40:10.327Z	[INFO] 2026-04-14T11:40:10.327Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [jobGold] Estado: SUCCEEDED | 90s decorridos
2026-04-14T11:40:10.327Z	[INFO] 2026-04-14T11:40:10.327Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Job Gold concluido!
2026-04-14T11:40:11.906Z	[INFO] 2026-04-14T11:40:11.906Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Crawler Gold iniciado!
2026-04-14T11:40:11.952Z	[INFO] 2026-04-14T11:40:11.951Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-gold] Estado: RUNNING | 0s decorridos
2026-04-14T11:40:42.012Z	[INFO] 2026-04-14T11:40:42.012Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-gold] Estado: RUNNING | 30s decorridos
2026-04-14T11:41:12.056Z	[INFO] 2026-04-14T11:41:12.056Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-gold] Estado: RUNNING | 60s decorridos
2026-04-14T11:41:42.100Z	[INFO] 2026-04-14T11:41:42.100Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-gold] Estado: STOPPING | 90s decorridos
2026-04-14T11:42:12.142Z	[INFO] 2026-04-14T11:42:12.142Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-gold] Estado: STOPPING | 120s decorridos
2026-04-14T11:42:42.176Z	[INFO] 2026-04-14T11:42:42.176Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 [crawler-shopbr-gold] Estado: READY | 150s decorridos
2026-04-14T11:42:42.176Z	[INFO] 2026-04-14T11:42:42.176Z c69f5978-7d0a-4890-8ca5-4a6bb838f889 Crawler Gold concluido!
2026-04-14T11:42:42.187Z	END RequestId: c69f5978-7d0a-4890-8ca5-4a6bb838f889
2026-04-14T11:42:42.187Z	REPORT RequestId: c69f5978-7d0a-4890-8ca5-4a6bb838f889 Duration: 525076.58 ms Billed Duration: 525418 ms Memory Size: 128 MB Max Memory Used: 93 MB Init Duration: 341.34 ms
	No newer events at this moment. Auto retry paused. Resume

Back to top

Camada Silver: Processing

Processing

O que acontece nessa camada

O Glue Job Silver lê os CSVs do Bronze, aplica as transformações via PySpark e salva os dados limpos em formato Parquet na camada Silver, particionado por estado. O particionamento é uma decisão técnica importante: o Athena cobra por dado escaneado — ao particionar, uma query de SP lê apenas a partição estado=SP.

Remove nulos

Linhas com pedido_id ou valor nulo são descartadas. Dado inválido não avança para análise.

Filtra cancelados

Pedidos com status cancelado são removidos. O Silver reflete apenas dados operacionais ativos.

Converte tipos

valor → double, data_pedido → DATE, estado → uppercase. Schema tipado e consistente.

Parquet + partição

Salva em Parquet particionado por estado. CSV de 100MB vira ~15MB. Redução de custo de até 90% no Athena.

AWS Glue Job

Processing

AWS Glue Studio Info

Create job Info

Author in a visual interface focused on data flow.
Visual ETL

Author using an interactive code notebook.
Notebook

Author code with a script editor.
Script editor

Example jobs Info

Create example job

Your jobs (2) Info

Actions | Run job

Filter jobs by property

1

Job name	Type	Created by	Last modified	AWS Glue version	Action
jobGold	Glue ETL	Script	12/04/2026, 12:35:59	5.0	Upgrade with AI
job	Glue ETL	Script	12/04/2026, 12:23:29	5.0	Upgrade with AI

AWS Glue Job Silver: Script PySpark

Processing

job

Script | Job details | Runs | Data quality | Schedules | Version Control

Script Info

```python
import sys
from awsglue.context import GlueContext
from pyspark.context import SparkContext
from pyspark.sql.functions import col, upper, to_date
from pyspark.sql.types import StructType, StructField, StringType, DoubleType

sc = SparkContext()
glueContext = GlueContext(sc)
spark = glueContext.spark_session

schema = StructType([
    StructField("pedido_id", StringType(), True),
    StructField("cliente_id", StringType(), True),
    StructField("produto", StringType(), True),
    StructField("categoria", StringType(), True),
    StructField("valor", DoubleType(), True),
    StructField("status", StringType(), True),
    StructField("estado", StringType(), True),
    StructField("data_pedido", StringType(), True)
])

df_raw = spark.read.option("header", "true").schema(schema).csv("s3://shopbr-datalake-joyce/bronze/pedidos/")

df_clean = df_raw \
    .dropna(subset=["pedido_id", "valor"]) \
    .filter(col("status") != "cancelado") \
    .withColumn("valor", col("valor").cast("double")) \
    .withColumn("estado", upper(col("estado"))) \
    .withColumn("data_pedido", to_date(col("data_pedido"), "yyyy-MM-dd"))

df_clean.write.partitionBy("estado").mode("overwrite").parquet("s3://shopbr-datalake-joyce/silver/pedidos_limpos/")

print(f"Registros processados: {df_clean.count()}")
print("Job concluido com sucesso!")
```

AWS Glue Job Silver: Execução

Processing

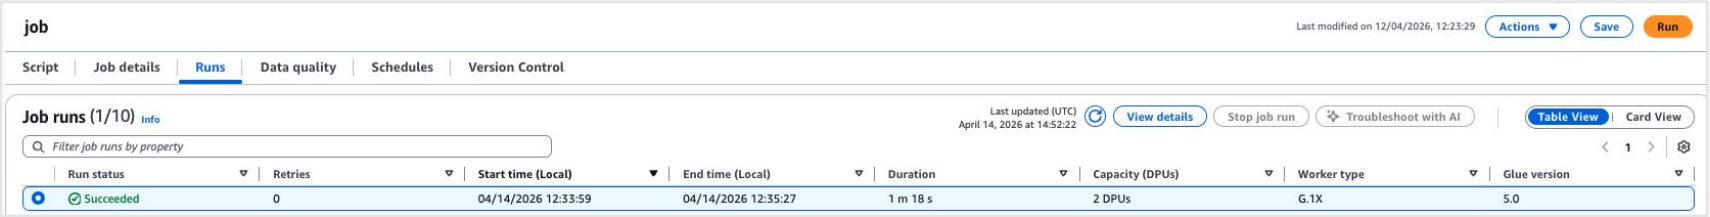

Amazon S3: silver/pedidos_limpos/ particionado

Processing

shopbr-datalake-joyce > silver/ > pedidos_limpos/

pedidos_limpos/

Copy S3 URI

Objects | Properties

Objects (9)

Copy S3 URI | Copy URL | Download | Open | Delete | Actions | Create folder | Upload

Objects are the fundamental entities stored in Amazon S3. You can use Amazon S3 inventory to get a list of all objects in your bucket. For others to access your objects, you'll need to explicitly grant them permissions. Learn more

Find objects by prefix

Show versions

1

Name	Type	Last modified	Size	Storage class
estado=AM/	Folder	-	-	-
estado=BA/	Folder	-	-	-
estado=GO/	Folder	-	-	-
estado=MG/	Folder	-	-	-
estado=PR/	Folder	-	-	-
estado=RJ/	Folder	-	-	-
estado=RS/	Folder	-	-	-
estado=SC/	Folder	-	-	-
estado=SP/	Folder	-	-	-

Camada Gold: Analytics

Analytics

O que acontece nessa camada

O Glue Job Gold lê os dados limpos do Silver e produz agregações prontas para o time de negócio consumir via Athena. Nenhuma transformação de limpeza é feita aqui,apenas agregação. O Gold responde perguntas como: qual estado gerou mais receita? Quantos pedidos foram feitos por mês?

O que o Gold produz

- Lê os dados do Silver (pedidos_limpos/)
- Cria a coluna mes a partir de data_pedido no formato yyyy-MM
- Agrupa por estado e mes
- Calcula total_vendas (soma do valor) e qtd_pedidos (contagem)
- Salva em Parquet em gold/vendas_mensais/ com .mode('overwrite'): garante que não há duplicação

AWS Glue Job Gold: Script PySpark

Analytics

jobGold

Script | Job details | Runs | Data quality | Schedules | Version Control

Script Info

```python
import sys
from awsglue.context import GlueContext
from pyspark.context import SparkContext
from pyspark.sql.functions import col, sum, count, date_format

sc = SparkContext()
glueContext = GlueContext(sc)
spark = glueContext.spark_session

df_silver = spark.read.parquet("s3://shopbr-datalake-joyce/silver/pedidos_limpos/")

df_gold = df_silver \
    .withColumn("mes", date_format(col("data_pedido"), "yyyy-MM")) \
    .groupBy("estado", "mes") \
    .agg(
        sum("valor").alias("total_vendas"),
        count("pedido_id").alias("qtd_pedidos")
    ) \
    .orderBy("estado", "mes")

total = df_gold.count()
df_gold.write.mode("overwrite").parquet("s3://shopbr-datalake-joyce/gold/vendas_mensais/")
print(f"Registros gerados: {total}")
print("Job Gold concluido com sucesso!")
```

AWS Glue Job Gold: Execução

Analytics

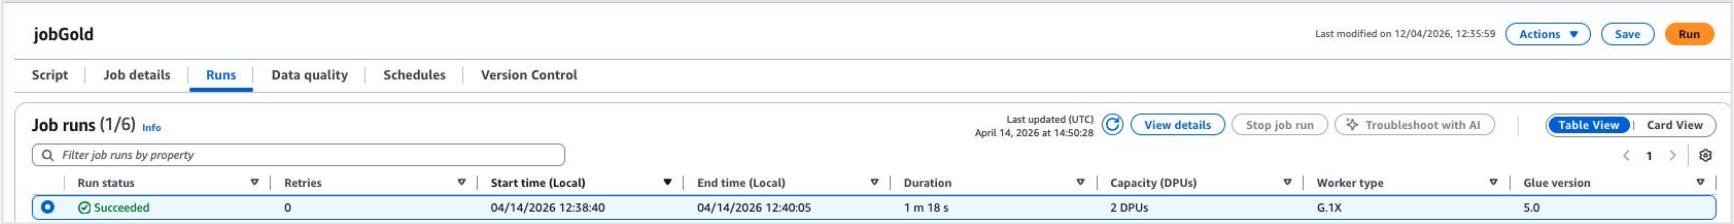

Amazon S3: gold/vendas_mensais/

Analytics

shopbr-datalake-joyce > gold/ > vendas_mensais/

vendas_mensais/

Copy S3 URI

Objects | Properties

Objects (1)

Copy S3 URI | Copy URL | Download | Open | Delete | Actions | Create folder | Upload

Objects are the fundamental entities stored in Amazon S3. You can use Amazon S3 inventory to get a list of all objects in your bucket. For others to access your objects, you'll need to explicitly grant them permissions. Learn more

Find objects by prefix

Show versions

1

Name	Type	Last modified	Size	Storage class
part-00000-e997a68e-735a-4d4c-a99e-fd83f7cb453b-c000.snappy.parquet	parquet	April 14, 2026, 12:39:54 (UTC+01:00)	1.4 KB	Standard

Glue Crawler e Data Catalog

Catalogação

Duas peças com propósitos distintos

Uma distinção importante: o Glue Job lê diretamente do S3, ele não depende do Crawler. O Crawler existe para o Athena. São duas automações independentes.

Glue Crawler

- Varre as pastas do S3 após cada job
- Detecta automaticamente o schema dos arquivos
- Registra as tabelas no Glue Data Catalog
- Sem ele, o Athena não encontra os dados
- 3 crawlers configurados: bronze, silver e gold

Glue Data Catalog

- Índice central de todos os dados da conta AWS
- Criado automaticamente pela AWS — único por conta
- Contém os databases criados (shopbr_catalog_bronze, silver, gold)
- As tabelas são criadas pelo Crawler ao rodar
- O Athena usa o Catalog para encontrar e ler os dados

AWS Glue: Crawlers

Catalogação

Crawlers

A crawler connects to a data store, progresses through a prioritized list of classifiers to determine the schema for your data, and then creates metadata tables in your data catalog.

Crawlers (3) Info

Last updated (UTC)
April 14, 2026 at 14:53:22

Action | Run | Create crawler

View and manage all available crawlers.

Filter crawlers

1

Name	State	Schedule	Last run	Last run timestamp	Log	Table changes from last run
crawler-shopbr-bronze	Ready		Succeeded	April 12, 2026 at 12:00:25	View log	-
crawler-shopbr-gold	Ready		Succeeded	April 14, 2026 at 11:40:10	View log	-
crawler-shopbr-silver	Ready		Succeeded	April 14, 2026 at 11:35:30	View log	1 updated

Glue Data Catalog: Databases

Catalogação

Databases (5)

A database is a set of associated table definitions, organized into a logical group.

Last updated (UTC)
April 14, 2026 at 14:53:40

Edit | Delete | Add database

Choose catalog

276460385037

Filter databases

1

Name	Description	Location URI	Source catalog	Created on (UTC)
default	-	-	276460385037	April 14, 2026 at 09:44:08
shopbr_catalog	-	-	276460385037	April 2, 2026 at 22:47:46
shopbr_catalog_bronze	-	-	276460385037	April 12, 2026 at 11:43:18
shopbr_catalog_gold	-	-	276460385037	April 14, 2026 at 10:54:57
shopbr_catalog_silver	-	-	276460385037	April 14, 2026 at 09:59:14

Glue Data Catalog: Schema Bronze

Catalogação

table_pedidos

Last updated (UTC)
April 14, 2026 at 14:53:51

Version 0 (Current version) | Actions

Table overview | Data quality - *new*

Table details

Name
table_pedidos

Database
shopbr_catalog_bronze

Description
-

Last updated
April 14, 2026 at 09:47:24

Classification
-

Location
s3://shopbr-datalake-joyce/bronze/pedidos

Connection
-

Deprecated
-

Column statistics
No statistics

Advanced properties

Schema | Partitions | Indexes | Column statistics - *new*

Schema (8)

View and manage the table schema.

Edit schema as JSON | Edit schema

Filter schemas

1

#	Column name	Data type	Partition key	Comment
1	pedido_id	string	-	-
2	cliente_id	string	-	-
3	produto	string	-	-
4	categoria	string	-	-
5	valor	double	-	-
6	status	string	-	-
7	estado	string	-	-
8	data_pedido	string	-	-

Glue Data Catalog: Schema Silver

Catalogação

pedidos_limpos

Last updated (UTC)
April 14, 2026 at 14:54:39

Version 0 (Current version) | Actions

Table overview | Data quality - *new*

Table details

Name
pedidos_limpos

Database
shopbr_catalog_silver

Description
-

Last updated
April 14, 2026 at 10:29:02

Classification
-

Location
s3://shopbr-datalake-joyce/silver/pedidos_limpos

Connection
-

Deprecated
-

Column statistics
No statistics

▸ Advanced properties

Schema | Partitions | Indexes | Column statistics - *new*

Schema (8)

View and manage the table schema.

Edit schema as JSON | Edit schema

Filter schemas

1

#	Column name	Data type	Partition key	Comment
1	pedido_id	string	-	-
2	cliente_id	string	-	-
3	produto	string	-	-
4	categoria	string	-	-
5	valor	double	-	-
6	status	string	-	-
7	data_pedido	date	-	-
8	estado	string	Partition (0)	-

Glue Data Catalog: Schema Gold

Catalogação

vendas_mensais

Last updated (UTC)
April 14, 2026 at 14:54:17

Version 0 (Current version) | Actions

Table overview | Data quality - *new*

Table details

Name
vendas_mensais

Database
shopbr_catalog_gold

Description
-

Last updated
April 14, 2026 at 10:55:18

Classification
-

Location
s3://shopbr-datalake-joyce/gold/vendas_mensais

Connection
-

Deprecated
-

Column statistics
No statistics

▸ Advanced properties

Schema | Partitions | Indexes | Column statistics - *new*

Schema (4)

View and manage the table schema.

Edit schema as JSON | Edit schema

Filter schemas

1

#	Column name	Data type	Partition key	Comment
1	estado	string	-	-
2	mes	string	-	-
3	total_vendas	double	-	-
4	qtd_pedidos	bigint	-	-

Athena: Consultas SQL

Consumo

Como o Athena funciona nesse pipeline

O Athena executa queries SQL diretamente nos arquivos armazenados no S3, sem precisar carregar os dados em um banco de dados. Ele usa o Glue Data Catalog para saber onde os dados estão e qual é o schema de cada tabela.

Perguntas respondidas com SQL

Query : Vendas por Categoria

Qual categoria gera mais receita? Qual é o ticket médio por categoria?

Query 2: Vendas por Estado

Qual estado do Brasil concentra mais vendas e receita?

Query 3: Pedidos por Status

Quantos pedidos estão entregues, em trânsito ou cancelados?

Query 4: Top 5 Produtos

Quais produtos mais venderam e geraram mais receita?

Athena: Data

Consumo

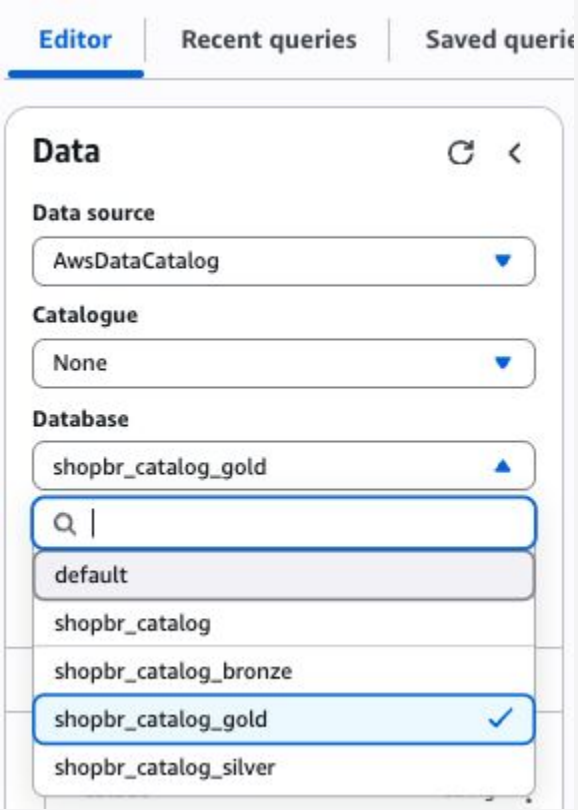

Athena: Query 1 Vendas por Categoria

Consumo

```sql
SELECT
    categoria,
    COUNT(*) AS total_pedidos,
    ROUND(SUM(valor), 2) AS receita_total,
    ROUND(AVG(valor), 2) AS ticket_medio
FROM shopbr_catalog_silver.pedidos_limpos
GROUP BY categoria
ORDER BY receita_total DESC;
```

SQL Ln 8, Col 29

Run again | Explain | Cancel | Clear | Create

Reuse query results
up to 60 minutes ago

Query results | Query status

Completed — Time in queue: 108 ms — Run time: 820 ms — Data scanned: 0.51 KB

Results (3)

Copy | Download results CSV

Search rows

1

#	categoria	total_pedidos	receita_total	ticket_medio
1	Eletrônicos	4	5996.9	1499.23
2	Moda	2	478.9	239.45
3	Utilidades	1	219.0	219.0

Athena: Query 2 Vendas por Estado

Consumo

```sql
SELECT
    estado,
    COUNT(*) AS total_pedidos,
    ROUND(SUM(valor), 2) AS receita_total
FROM shopbr_catalog_silver.pedidos_limpos
GROUP BY estado
ORDER BY receita_total DESC
LIMIT 10;
```

SQL Ln 17, Col 10

Run again | Explain | Cancel | Clear | Create

Reuse query results
up to 60 minutes ago

Query results | Query status

Completed — Time in queue: 117 ms — Run time: 657 ms — Data scanned: 0.24 KB

Results (6)

Copy | Download results CSV

Search rows

1

#	estado	total_pedidos	receita_total
1	RS	1	3499.0
2	SP	2	1598.9
3	PR	1	899.0
4	RJ	1	349.0
5	MG	1	219.0
6	BA	1	129.9

Athena: Query 3 Pedidos por Status

Consumo

```sql
#pedidos por status
SELECT
    status,
    COUNT(*) AS total,
    ROUND(SUM(valor), 2) AS valor_total
FROM shopbr_catalog_bronze.table_pedidos
GROUP BY status;
```

SQL Ln 25, Col 40

Run | Explain | Cancel | Clear | Create

Reuse query results
up to 60 minutes ago

Query results | Query status

Completed — Time in queue: 121 ms — Run time: 441 ms — Data scanned: 0.58 KB

Results (3)

Copy | Download results CSV

Search rows

1

#	status	total	valor_total
1	entregue	6	3195.8
2	cancelado	1	189.9
3	em_transito	1	3499.0

Athena: Query 4 Top 5 Produtos

Consumo

```sql
#top 5 produtos

SELECT
    produto,
    categoria,
    COUNT(*) AS vezes_vendido,
    ROUND(SUM(valor), 2) AS receita
FROM shopbr_catalog_silver.pedidos_limpos
GROUP BY produto, categoria
ORDER BY receita DESC
LIMIT 5;
```

SQL Ln 35, Col 36

Run again | Explain | Cancel | Clear | Create

Reuse query results
up to 60 minutes ago

Query results | Query status

Completed — Time in queue: 103 ms — Run time: 752 ms — Data scanned: 0.81 KB

Results (5)

Copy | Download results CSV

Search rows

1

#	produto	categoria	vezes_vendido	receita
1	Notebook Pro	Eletrônicos	1	3499.0
2	Smartphone X	Eletrônicos	1	1299.9
3	Tablet 10	Eletrônicos	1	899.0
4	Tênis Running	Moda	1	349.0
5	Fone Bluetooth	Eletrônicos	1	299.0

Decisões técnicas

Engenharia

Por que cada escolha foi feita

Polling manual no Lambda

O waiter nativo do Glue bloqueia a execução. O Lambda tem timeout de 15 min e jobs Glue podem demorar mais. Polling com intervalo configurável é mais resiliente.

Parquet em vez de CSV

O Athena cobra por dado escaneado. Parquet comprime e é colunar, lê só as colunas necessárias. Redução de custo de até 90% comparado ao CSV.

Particionamento por estado

Uma query filtrando SP lê apenas estado=SP, não o dataset inteiro. Decisão de performance e custo que escala bem com volume crescente.

.mode('overwrite')

Garante idempotência, o pipeline pode ser reexecutado sem gerar duplicações. Comportamento previsível e seguro para reprocessamentos.

Próximos passos

Evolução

O que poderia ser evoluído nessa arquitetura

Região sa-east-1

Migrar para São Paulo, menor latência no Brasil

VPC e IAM granular

Rede privada e roles com permissão mínima por serviço

Crawlers agendados

Schedule CRON no Glue para catalogação automática

Jobs por domínio

Pipelines separados para clientes, produtos e estoque

Views no Athena

Queries salvas prontas para o time de negócio

Alertas CloudWatch

Notificações automáticas em caso de falha no pipeline

Obrigada

Pipeline de Dados na AWS · ShopBR

Medallion Architecture · S3 · Lambda · Glue · Athena · CloudWatch

Joyce Mara · 2026